Projeto Final: Aprendizagem de Máquina (IN1102, pós)

Modelo tema: **TabICL v2 (*Tabular In-Context Learning v2*)**

Grupo: **Douglas Araújo Silva, Felipe Araújo de Lima, Letícia De Albuquerque S. Leitão**

Pós-graduação, CIn/UFPE, 2026.2

Apresentação

Agenda

Etapa 1: fundamentação teórica do modelo (10 minutos)

- Motivação, contexto e intuição
- Arquitetura, formulação e forma de aprendizado
- Complexidade, hiperparâmetros e posicionamento na literatura
- Aplicações e limitações

Etapa 2: estudo experimental (10 minutos)

- Seleção dos 30 datasets e protocolo de treino, validação e teste
- Estudo de overfitting e viés-variância
- Resultados no teste e teste de Friedman (Iman-Davenport)
- Controle com Holm e Bonferroni-Dunn; Nemenyi e diagrama CD
- Padrão vs. com busca, regimes, custo e conclusões

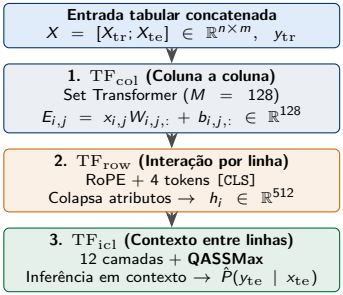
Etapa 1: motivação e contexto

- Classificação tabular: *gradient boosting* (XGBoost, LightGBM, CatBoost) ainda é referência pela eficiência e robustez a atributos heterogêneos, escalas irregulares e dados ausentes (Grinsztajn et al., 2022; McElfresh et al., 2023).
- Novos paradigmas: modelos de fundação com aprendizado em contexto (*In-Context Learning* — ICL / PFNs), MLPs modernas (RealMLP, TabM), modelos aditivos (EBM, APLR), métodos de vizinhança (TabR, ModernNCA) e de *kernels* (xRFM).
- **Pergunta:** em quais regimes o modelo **TabICL v2** é competitivo com LightGBM, XGBoost e CatBoost (*Tuned Defaults* do `pytabkit`)?

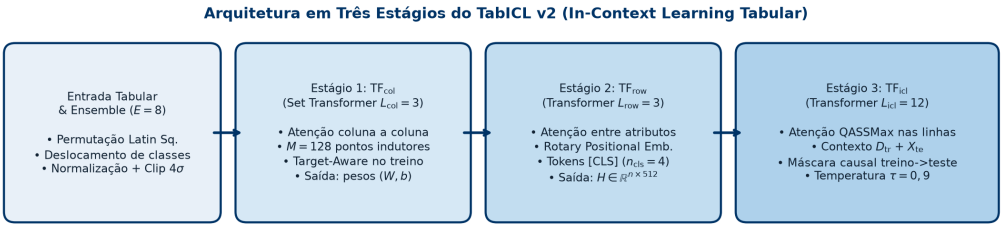
Contexto histórico: das *Prior-Data Fitted Networks* e TabPFN v1/v2 (Hollmann et al., 2023, *Nature* 2025), limitados pelo custo de atenção bidimensional célula a célula $\mathcal{O}(n^2m + nm^2)$, à decomposição coluna-depois-linha do TabICL v1 (Qu et al., ICML 2025) e ao TabICL v2 (Qu et al., 2026, INRIA Saclay).

Etapa 1: intuição do modelo

- **Ideia central em uma frase:** transformar o treino rotulado $\mathcal{D}_{\text{tr}}$ em contexto e inferir $P(y_{\text{te}} \mid x_{\text{te}}, \mathcal{D}_{\text{tr}})$ em uma única passagem direta, sem gradientes em `fit()`.
- **Diferença em relação aos baselines:** GBDTs particionam os eixos iterativamente; o TabICL v2 usa $\approx$ 33M de pesos congelados e desacopla atenção por coluna e por linha ($\text{TF}_{\text{col}} \to \text{TF}_{\text{row}} \to \text{TF}_{\text{icl}}$), reduzindo o custo de $\mathcal{O}(n^2 m)$ para $\mathcal{O}(n^2 + nm^2)$.
- **Fundamento teórico ou heurístico:** aproximação amortizada da Distribuição Preditiva Posterior (PPD) Bayesiana sob prior de SCMs, Cauchy e kernels de Sobolev.



Etapa 1: arquitetura



Complexidade assintótica por estimador: $\mathcal{O}(m \cdot n \cdot M)$ no Estágio 1 + $\mathcal{O}(n \cdot m^2)$ no Estágio 2 + $\mathcal{O}(n^2)$ no Estágio 3

Componentes principais: [Bloco A: $\mathrm{TF}_{\mathrm{col}}$] $L_{\mathrm{col}} = 3$ blocos ISAB ($d_{\mathrm{col}} = 128, M = 128$, *Repeated Feature Grouping* + *Early Target-Aware Embedding* restrito ao treino) $\rightarrow$ transformação afim por célula $E_{i,j} = x_{i,j} W_{i,j,:} + b_{i,j,:}$; **[Bloco B: $\mathrm{TF}_{\mathrm{row}}$]** $L_{\mathrm{row}} = 3$ camadas ($h_{\mathrm{row}} = 8$, RoPE) sobre $m + 4$ tokens $\rightarrow d_{\mathrm{icl}} = 512$; **[Bloco C: $\mathrm{TF}_{\mathrm{icl}}$]** $L_{\mathrm{icl}} = 12$ camadas ($h_{\mathrm{icl}} = 4$) com escala logarítmica **QASSMax** $s_{\mathrm{base}}(n_{\mathrm{ctx}}) = 1 + \mathrm{softplus}(\alpha) \log(n_{\mathrm{ctx}})$ e ensemble de $E = 8$ visões.

Etapa 1: formulação e forma de aprendizado

- **Função de perda:** no pré-treinamento, minimiza a entropia cruzada esperada sob tarefas sintéticas $D \sim p(\mathcal{T})$: $\mathcal{L}(\theta) = \mathbb{E}_D\big[-\sum \log p_\theta(y_{\text{te}} \mid x_{\text{te}}, \mathcal{D}_{\text{tr}})\big]$, aproximando a PPD Bayesiana.
- **Regularização:** prior causal pré-treinado (pesos 100% congelados na inferência), truncamento simétrico de outliers em $[-\tau_{\text{out}}, +\tau_{\text{out}}]$ e ensemble de $E = 8$ visões por quadrados latinos.
- **Como aprende:** pré-treinado offline em $\approx$ 220M de tabelas sintéticas com otimizador matricial **Muon** (Newton-Schulz); em dados reais, opera puramente por **aprendizagem em contexto (ICL)**, com zero gradientes em `fit()`.
- **Representação dos padrões:** incorporação afim de células no TF_{col} ($\mathbb{R}^{128}$), representação condensada por instância no TF_{row} ($\mathbb{R}^{512}$) e atenção contextual com QASSMax no TF_{icl} (decomposição de base mista se $C > 10$).
- **Categóricos e valores ausentes:** nativo em `fit()` — `OrdinalEncoder` com código para categorias não vistas, imputação de ausentes pela mediana de X_{tr} e normalizações (`none`, `power`, `quantile_rtdl`).

Etapa 1: complexidade computacional

Operação	Tempo	Memória	Observação (confronto medido)
Treino (`fit`)	$\mathcal{O}(E \cdot n_{\mathrm{tr}} \cdot p)$	$\mathcal{O}(E \cdot n_{\mathrm{tr}} \cdot p)$	Apenas visões em CPU; mediana **1,37 s** (média **3,86 s**) em `group_default` no teste.
Inferência (`predict`)	$\mathcal{O}\big(E(npM + np^2 + n^2)\big)$	$\mathcal{O}(npd_{\mathrm{col}} + np^2 + n^2)$	Passagem pelos 3 Transformers em GPU; mediana **3,15 s** (média **18,38 s**, até > 120 s se $p > 1.600$).

Pico de memória observado: saturação dos **15.360 MiB (15 GiB) de VRAM** e RAM paginada (`exit code` 137) em `Bioresponse` ($p = 1.776$) e `hiva_agnostic` ($p = 1.617$) na validação, mitigada pelo wrapper `AdaptiveTabICLClassifier` (`batch_size=1` e `disk_offload_dir` quando $p > 500$); alocação de $\approx 12,68$ **GB de VRAM** em `customer_satisfaction_in_airline` ($n = 129.880$, $n_{\mathrm{te}} = 43.293$) no teste; **hardware:** GPU NVIDIA Tesla T4 (16 GB VRAM, CUDA 12.4) + CPU Intel Xeon.

Etapa 1: hiperparâmetros e espaço de busca

Hiperparâmetro	Padrão	Faixa de busca (Optuna)	Efeito esperado
`norm_methods`	`["none","power"]`	5 combinações categóricas (`none+power`, `+robust`, `+quantile_rtdl`, `power`, `quantile_rtdl`)	Adapta visões do ensemble a distribuições assimétricas, multimodais ou com caudas pesadas (reduz viés de representação).
`outlier_threshold`	4,0	[2,5; 6,0] (contínuo, linear)	Compromisso entre truncar outliers espúrios na atenção (τ_{out} baixo) e preservar sinal informativo nas caudas (τ_{out} alto).
`softmax_temperature`	0,9	[0,5; 1,5] (contínuo, escala log)	Controla a nitidez dos logits antes da agregação; afeta fortemente a entropia cruzada e suaviza probabilidades extremas.
`average_logits`	`True`	$\{\texttt{True}, \texttt{False}\}$ (categórico)	Combina os E estimadores por produto geométrico normalizado (logits) vs. mistura linear de probabilidades.
`n_estimators`	8	Fixo em 8 na busca (curva: $\{1, 2, 4, 8, 16, 32\}$)	Reduz monotonicamente a variância de permutação de colunas/classes em proporção linear ao tempo de inferência $\mathcal{O}(E)$.

Fonte das faixas: artigo original do TabICL v2 (Qu et al., 2026), documentação oficial do `TabICLClassifier` (`tabicl 2.2.0`) e literatura de pré-processamento quantílico RTDL (Gorishniy et al., 2021), declaradas em `docs/declaracoes_a_priori.md` sem uso do leaderboard.

Etapa 1: posicionamento na literatura

- **2023: TabPFN v1** (Hollmann et al., ICLR 2023) introduz fundação por ICL em priors de SCMs, restrito a $n \leq 1.000, p \leq 100$.
- **2024: Tuned Defaults / `pytabkit`** (Holzmüller et al., NeurIPS 2024) consolida baselines GBDT fortes; **TabR** (Gorishniy et al., ICLR 2024) integra k-NN em redes tabulares treinadas por gradiente.
- **2025: TabPFN v2** (Hollmann et al., *Nature* 2025), benchmark vivo **TabArena** (Erickson et al., 2025) e **TabICL v1** (Qu et al., ICML 2025), desacoplando atenção de colunas e linhas.
- **2026: TabICL v2** (Qu et al., fev. 2026) lidera TabArena e TALENT superando TabPFN v2/2.5 e GBDTs sem exigir busca de hiperparâmetros.

O modelo TabICL v2 se diferencia por: (1) complexidade $\mathcal{O}(n^2 + np^2)$ via colapso por linha e atenção escalável QASSMax; e (2) pré-treinamento aberto (BSD-3-Clause) com otimizador Muon e prior sintético de Cauchy/Sobolev.

Etapa 1: aplicações e limitações

- **Aplicações práticas:** classificação tabular de pequeno e médio porte ($n \leq 10.000$, $p \leq 500$), prototipagem rápida sem HPO (*zero-shot*) e problemas exigindo baixa entropia cruzada (`group_default` obteve CE de 0,3005, vencendo em 29/30 bases).
- **Restrições de tamanho (n e p máximos, número de classes):** escala $\mathcal{O}(np^2)$ exige descarregamento em disco para $p > 500$ (como `Bioresponse`, $p = 1.776$); suporta $C \leq 10$ diretamente e $C > 10$ via decomposição hierárquica mista.
- **Suposições sobre os dados (IID, tipos de atributos):** assume instâncias IID no contexto e colunas numéricas ou categóricas/ordinais; não substitui modelos dedicados para texto livre bruto ou séries temporais longas.
- **Requisitos:** requer **GPU com** ≥ 16 **GB de VRAM** para inferência rápida (18,38 s médios/fold em GPU vs. 0,19–0,56 s dos GBDTs em CPU); pesos e código sob licença aberta **BSD-3-Clause**.

Etapa 2: datasets, sistemas e métricas

- **Datasets:** 30 do TabArena-v0.1 (OpenML 457: 10 pequenos, 10 médios, 10 grandes até $n = 129.880$), escolhidos pelo catálogo antes de qualquer resultado (`check_selection` ok); **critério:** equilíbrio entre binários (24) e multiclasse (6), atributos categóricos (15 $<$ 25% e 15 $\geq$ 25%) e dados ausentes (6).
- **Sistemas: TabICL v2 padrão** (`group_default`) e **TabICL v2 com busca** (`group_tuned`, controle); **LightGBM**, **CatBoost** e **XGBoost** (*Tuned Defaults* do `pytabkit`, via `ImputedClassifier`).
- **Busca:** Optuna (TPE, `seed=42+fold`) no treino de cada fold externo, 20 tentativas, CV interna de 3 folds, limite de 600 s (tempo efetivo no teste: mediana **170,67 s**, máx. **717,95 s**), subamostra de até 10.000.
- **Espaço de busca:** 4 hiperparâmetros (`norm_methods`, `outlier_threshold`, `softmax_temperature`, `average_logits`) justificados a priori por Qu et al. (2026), documentação e Gorishniy et al. (2021).
- **Métricas: AUC OvO** (primária), Acurácia (ACC), G-Mean, Entropia Cruzada (CE, secundária) e custo computacional (s).

Etapa 2: protocolo de treino, validação e teste (CV aninhada)



Treino de cada fold externo: CV interna de 3 folds com a busca e todos os estudos (sensibilidade, específico, curvas, overfitting).

Teste de cada fold externo: selado; usado uma única vez.

1. Desenvolvimento
`run_validation`, notebooks 02, 03 e 05
`validation.csv` (diagnóstico)

→

2. Congelamento
`freeze` e `git commit`
`protocolo.lock`: hashes e orçamento

→

3. Avaliação final única
`final_test` e `git commit`
`test.csv`, `test_log.csv`; `check_protocol`

→

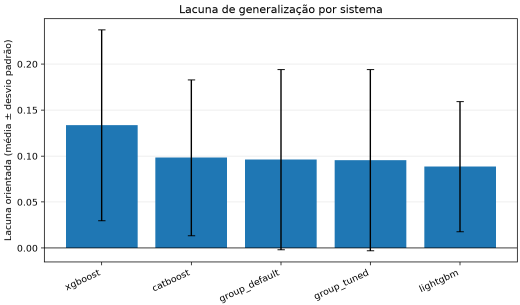
4. Análise
média dos 3 testes por dataset
Demšar com $N = 30$

Lock: commit 9718c9649b (árvore 0595782f, anterior ao 1º commit de resultados 983c42aa4f), sha256 59901430bd8c...; **execuções em `test_log.csv`:** 5 (`1 inicial resume=False + 4 retomadas resume=True` apenas de pendências/OOM, 450/450 ok); `check_protocol`: **APROVADO**. **Declarados a priori (`e2c6968`):** espaço de 4 HPs, bases de estudo (363621, 363704, 363628) e grades de complexidade.

Etapa 2: overfitting, lacuna treino-validação

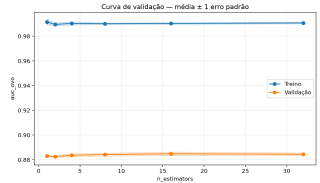
Sistema	Treino	Val.	Lacuna geral
TabICL v2 padrão	0,9505	0,8542	$0{,}0963 \pm 0{,}0980$
TabICL v2 c/ busca*	0,9511	**0,8556**	$0{,}0955 \pm 0{,}0985$
LightGBM (TD)	0,9190	0,8304	**0,0886** $\pm 0{,}0708$
XGBoost (TD)	0,9525	0,8190	$0{,}1335 \pm 0{,}1038$
CatBoost (TD)	0,9311	0,8328	$0{,}0983 \pm 0{,}0846$

*AUC OvO em 270 partições internas (`validation_train.csv` vs. `validation.csv`); em `group_tuned`, a validação é otimista (`optimistic=True`).

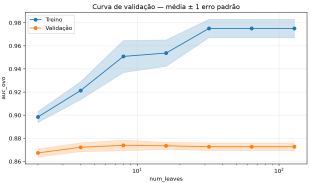


Leitura: maior lacuna ocorre no **XGBoost (**0,1335**)** e **CatBoost (**0,0983**)**, especialmente no regime **pequeno (**0,1585 **e** 0,1313**)**, onde árvores profundas memorizam ruído amostral ($\mathrm{AUC}_{\mathrm{val}} = 0{,}8056$ no XGBoost pequeno). **Cautelas:** (1) no TabICL v2, $\mathrm{AUC}_{\mathrm{treino}} \approx 0{,}951$ (medida em subamostra de até 2.000 instâncias) decorre de *in-context lookup* (cada instância consultada já está presente com seu rótulo no contexto do $\mathrm{TF}_{\mathrm{icl}}$), não de ajuste de pesos; e (2) a validação de `group_tuned` (0,8556) tem viés otimista de seleção nos 3 folds internos.

Etapa 2: curvas de validação e regra de 1 erro padrão



TabICL v2: `n_estimators` $\in \{1, 2, 4, 8, 16, 32\}$ (363704, médio)



LightGBM: `num_leaves` $\in \{2, 4, 8, 16, 32, 64, 128\}$ (363704, médio)

- **Datasets (declarados a priori, um por regime, CV interna no fold 0):** 363621 (pequeno, $n = 748$), 363704 (médio, $n = 4.424$, 3 classes) e 363628 (grande, $n = 129.880$).
- **Melhor média vs. regra de 1 EP (`SIMPLER_IS_LOWER=True`):** TabICL v2 (`n_estimators`): melhor média $= \mathbf{16}, \mathbf{16}, \mathbf{32}$ (0,7552/0,8849/0,9915); regra de 1 EP $= \mathbf{1}, \mathbf{4}, \mathbf{1}$ (0,7525/0,8837/0,9906). Fixo a priori em $E = 8$ (dentro da banda de 1 EP nos 3 regimes). LightGBM (`num_leaves`): melhor média $= \mathbf{4}, \mathbf{8}, \mathbf{16}$; regra de 1 EP $= \mathbf{4}, \mathbf{4}, \mathbf{8}$.
- **Viés e variância:** LightGBM sobreajusta com `num_leaves` > 8; no TabICL v2, $E = 8$ situa-se no platô onde mais estimadores reduzem variância sem inflar viés (treino plano).
- **Erros por classe na validação (`preds_val/`):** menor recall na classe minoritária (`Yes` em 363621: 0,178 XGBoost vs. 0,271 TabICL; `Enrolled` em 363704: 0,426 **TabICL** vs. 0,349 XGBoost), justificando maior G-Mean do TabICL v2.

Etapa 2: resultados no teste (avaliação final única)

Sistema	AUC OvO (Teste)	Acurácia	G-Mean	Entropia Cruz.	Posto (AUC)	Tempo Med./Méd. (s)
TabICL v2 padrão	$\mathbf{0{,}8607 \pm 0{,}1170}$	$0{,}8703 \pm 0{,}0878$	$\mathbf{0{,}6548 \pm 0{,}2915}$	$\mathbf{0{,}3005 \pm 0{,}1633}$	N/A (1,20*)	**4,86** / 22,24
TabICL v2 c/ busca	$0{,}8606 \pm 0{,}1166$	$\mathbf{0{,}8704 \pm 0{,}0877}$	$0{,}6541 \pm 0{,}2923$	$0{,}3150 \pm 0{,}1673$	**1,30**	174,72 / 218,78
LightGBM (TD)	$0{,}8407 \pm 0{,}1190$	$0{,}8570 \pm 0{,}0905$	$0{,}6187 \pm 0{,}2834$	$0{,}3447 \pm 0{,}1613$	2,63	1,17 / 3,32
CatBoost (TD)	$0{,}8405 \pm 0{,}1159$	$0{,}8588 \pm 0{,}0866$	$0{,}6370 \pm 0{,}2668$	$0{,}4551 \pm 0{,}2569$	2,87	4,29 / 4,73
XGBoost (TD)	$0{,}8281 \pm 0{,}1259$	$0{,}8548 \pm 0{,}0885$	$0{,}6166 \pm 0{,}2718$	$0{,}4277 \pm 0{,}2120$	3,20	1,69 / 2,96

Média $\pm$ desvio entre os $N = 30$ datasets completos (média dos testes dos 3 folds externos por dataset em `results/test.csv`; *posto de `group_default` se comparado aos 3 baselines). **Incerteza via bootstrap ($B = 1.000$):** menor largura mediana de IC 95% em AUC OvO no TabICL v2 (0,0327 em `group_tuned` e 0,0329 em `group_default` vs. 0,0388–0,0410 nos baselines).

Validação interna vs. teste (AUC OvO): `group_default` subiu de 0,8542 para 0,8607 e `lightgbm` de 0,8304 para 0,8407 (maior volume de treino externo), mas a vantagem aparente de +0,0014 de `group_tuned` na validação (0,8556 vs. 0,8542, inflada pelo otimismo de seleção) desapareceu no teste selado (0,8606 vs. 0,8607).

Etapa 2: teste de Friedman com correção de Iman-Davenport

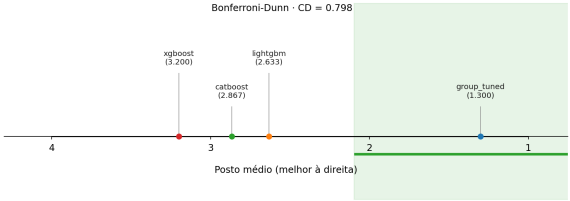
- **Configuração experimental:** $k = 4$ sistemas (`group_tuned` como controle vs. `lightgbm`, `catboost`, `xgboost`), $N = 30$ datasets independentes (média dos 3 folds externos por dataset), nível de significância $\alpha = 0{,}05$.
- **Métrica primária (AUC OvO):** $\chi_F^2 = \mathbf{37{,}480}$ ($p = 3{,}642 \times 10^{-8}$, gl $= 3$); estatística corrigida de Iman-Davenport:

$$F_F = \frac{(N-1)\chi_F^2}{N(k-1) - \chi_F^2} = \mathbf{20{,}695} \quad \text{com } (\mathbf{3}, \mathbf{87}) \text{ graus de liberdade;} \quad \mathbf{p = 3{,}284 \times 10^{-10}}.$$

- **Métrica secundária pré-declarada (Entropia Cruzada):** $\chi_F^2 = \mathbf{41{,}640}$ ($p = 4{,}781 \times 10^{-9}$); $F_F = \mathbf{24{,}970}$ com $(3, 87)$ gl; $\mathbf{p = 9{,}532 \times 10^{-12}}$ (postos: `group_tuned` 1,433, `lightgbm` 2,133, `catboost` 3,133, `xgboost` 3,300).
- **Decisão (por F_F, mais poderosa e menos conservadora que χ_F^2): rejeita-se fortemente a hipótese nula** H_0 ($p \ll 0{,}05$) em ambas as métricas, habilitando os pós-testes de Holm, Bonferroni-Dunn e Nemenyi.
- **Datasets excluídos pela regra de completude: nenhum (0 excluídos)**, pois todas as 450/450 combinações finalizaram com `status = ok`.

Etapa 2: modelo do grupo como controle (Holm e Bonferroni-Dunn)

vs. controle	z	p (Holm)
LightGBM (TD)	4,00	$\mathbf{6{,}33 \times 10^{-5}}$
CatBoost (TD)	4,70	$\mathbf{5{,}20 \times 10^{-6}}$
XGBoost (TD)	5,70	$\mathbf{3{,}59 \times 10^{-8}}$

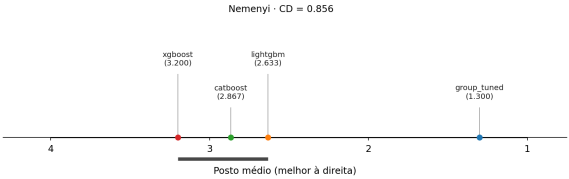


Diferença crítica de Bonferroni-Dunn ($k = 4, N = 30$): $\mathrm{CD}_{\mathrm{BD}} = \mathbf{0{,}798}$ ($q_{0,05} = 2{,}394 \times 0{,}3333$). Sistemas com posto $> R_{\mathrm{ctrl}} + \mathrm{CD}_{\mathrm{BD}} = \mathbf{2{,}098}$ são significativamente inferiores ao controle.

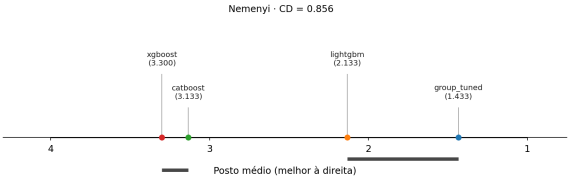
Conclusão: o TabICL v2 supera **todos os 3 baselines** com significância estatística tanto por Holm ($p \leq 6{,}33 \times 10^{-5}$) quanto por Bonferroni-Dunn em AUC OvO; na Entropia Cruzada, supera CatBoost e XGBoost por BD e todos os três por Holm ($p \leq 0{,}0357$).

Etapa 2: análise complementar (Nemenyi e diagrama CD)

Métrica primária: AUC OvO



Métrica secundária: Entropia Cruzada



$\mathrm{CD}_{\mathrm{Nem}} = 0{,}856$ ($q_{0,05} = 2{,}569 \times 0{,}3333$, controlando $\binom{4}{2} = 6$ pares):

- **Em AUC OvO:** `group_tuned` (1,300) fica **isolado em 1º lugar**; grupos sem diferença significativa (clique): **{`lightgbm` (2,633), `catboost` (2,867), `xgboost` (3,200)}** ($\Delta R_{\max} = 0{,}567 < 0{,}856$).
- **Em Entropia Cruzada:** grupos sem diferença significativa por Nemenyi: **{`group_tuned` (1,433), `lightgbm` (2,133)}** e **{`catboost` (3,133), `xgboost` (3,300)}**, pois `lightgbm` passa a superar significativamente `catboost` ($\Delta R = 1{,}000 > 0{,}856$) e `xgboost` ($\Delta R = 1{,}167 > 0{,}856$).

Etapa 2: padrão vs. com busca (Wilcoxon)

- **Diferenças usadas = 30 de $N = 30$:** em AUC OvO, $R^+ = 281{,}0$, $R^- = 184{,}0$, $T = 184{,}0$, $\mathbf{p = 0{,}3285}$ (não significativo); na Entropia Cruzada, $R^+ = 1{,}0$, $R^- = 464{,}0$, $T = 1{,}0$, $\mathbf{p = 3{,}725 \times 10^{-9}}$ a favor de `group_default`.
- **Vitórias, empates e derrotas da variante com busca (`group_tuned`): $\mathbf{18/0/12}$** em AUC OvO (0,8606 vs. 0,8607) e $\mathbf{1/0/29}$ em Entropia Cruzada (`group_default` vence em 29/30 bases).
- **Custo da busca:** tempo mediano de $\mathbf{170{,}67}$ s (média 196,49 s, máx. 717,95 s) por fold externo, multiplicando o tempo total por $\mathbf{9{,}84}\times$ (218,78 s vs. 22,24 s).
- **A busca compensa? Não.** O ganho em AUC é nulo ($p = 0{,}3285$), o tempo aumenta quase $10\times$ e a calibração/entropia cruzada piora significativamente em 29 dos 30 datasets.
- **Sensibilidade a 2 HPs e estudo específico (CV interna, notebook 03):** AUC OvO é quase plana em $\tau \in [0{,}5; 1{,}5]$ mas $\tau = 0{,}5$ infla a perda logarítmica (0,5419 $\rightarrow$ 0,6365), explicando por que otimizar AUC prejudica CE; $\tau_{\text{out}} \geq 4{,}0$, visões `["none","power"]` e $E = 8$ confirmam o ótimo do padrão.

Etapa 2: análise por regime (descritiva)

AUC OvO por regime de tamanho:

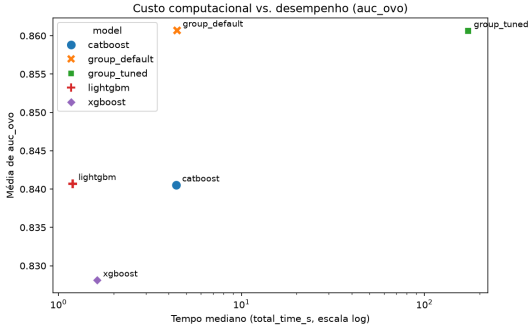
Sistema	Pequeno (10)	Médio (10)	Grande (10)
TabICL v2 padrão	**0,8751**	0,8615	**0,8455**
TabICL v2 c/ busca	**0,8751**	**0,8618**	0,8450
LightGBM (TD)	0,8423	0,8442	0,8355
CatBoost (TD)	0,8431	0,8452	0,8332
XGBoost (TD)	0,8158	0,8351	0,8334
Vantagem TabICL	**+3,20** p.p.	**+1,66** p.p.	**+0,95** p.p.
Posto médio TabICL	**1,00**	**1,30**	**1,60**

Síntese descritiva dos estratos:

- **Regime de tamanho:** o TabICL v2 é invicto no regime pequeno (10/10 vitórias, posto 1,00 e +3,20 p.p.); a vantagem decresce com n (+1,66 no médio e +0,95 no grande), onde GBDTs ganham volume amostral.
- **Tipo de tarefa:** lidera tanto em binários (0,8551 vs. 0,8337 do CatBoost, $N = 24$) quanto em multiclasse (0,8829 vs. 0,8762 do XGBoost, $N = 6$).
- **Atributos categóricos:** mantém dianteira tanto com poucos categóricos ($< 25\%$: 0,8759 vs. 0,8524, $N = 15$) quanto com muitos ($\geq 25\%$: 0,8454 vs. 0,8309, $N = 15$).
- **Dados ausentes:** maior robustez relativa com dados ausentes (0,8837 vs. 0,8614 do LightGBM e 0,8117 do XGBoost, $N = 6$), graças à imputação no $\mathrm{TF}_{\mathrm{col}}$.

Número de datasets por célula: $N_{\mathrm{cel}} \in \{6, 10, 15, 24\}$; **leitura apenas descritiva:** com amostras reduzidas ($N \leq 10$), a diferença crítica de Nemenyi sobe para $\mathrm{CD}_{N=10} = 1{,}483$ e $\mathrm{CD}_{N=6} = 1{,}915$, impedindo testes formais por estrato sem inflar o erro Tipo I.

Etapa 2: custo vs. desempenho



Posição do modelo do grupo na fronteira de Pareto: (1) Baixa latência em CPU (3–5 **s):** `xgboost` (2,96 s, AUC 0,8281) e `lightgbm` (3,32 s, AUC 0,8407); **(2) Ótimo de Pareto em predição (`group_default`,** 22,24 **s médios):** atinge a maior AUC (0,8607) e menor CE (0,3005) sem busca; e **(3) Dominado (`group_tuned`,** 218,78 **s):** custa 9,84× mais sem ganho em AUC (0,8606).

Etapa 2: pontos fortes, pontos fracos e ameaças à validade

- **Melhor desempenho em:** datasets pequenos e médios ou com desbalanceamento/ausentes (exemplos: `Marketing_Campaign` com $+\mathbf{0{,}0320}$ sobre LightGBM e $+0{,}3084$ sobre XGBoost; `Is-this-a-good-customer` com $+\mathbf{0{,}0610}$ sobre CatBoost; `maternal_health_risk` com $+\mathbf{0{,}0262}$ sobre XGBoost; e `polish_companies_bankruptcy` com $+\mathbf{0{,}0337}$ sobre CatBoost).
- **Pior desempenho em:** altíssima dimensionalidade esparsa com desbalanceamento extremo ou grandes tabelas com fronteiras simples (únicas 3 derrotas de `group_tuned`: `hiva_agnostic` com $-\mathbf{0{,}0226}$ vs. XGBoost, 0,4759 vs. 0,4985; `bank-marketing` com $-\mathbf{0{,}0069}$ vs. CatBoost; e `E-CommereShippingData` com $-\mathbf{0{,}0015}$ vs. LightGBM).
- **Causa provável:** o prior causal suave (SCMs/Sobolev) regulariza fortemente amostras pequenas sem sobreajustar, mas em `hiva_agnostic` ($p = 1.617$ colunas binárias esparsas, razão de desbalanceamento 88,33) o agrupamento de atributos e a atenção densa diluem sinais raros que divisões de árvores isolam.
- **Ameaças à validade: (i) Assimetria de busca:** baselines usaram *Tuned Defaults* fixos (`tune_time_s` $= 0$), mas o sucesso de `group_default` (`tune_time_s` $= 0$, AUC 0,8607) confirma que o ganho vem da arquitetura; **(ii) Imputação:** `ImputedClassifier` (ordinal + mediana) nos baselines vs. visões nativas no TabICL; **(iii) Subamostragem:** teto `MAX_SAMPLES` $= 10.000$ limita GBDTs no regime grande; **(iv) Falhas/retomadas:** 4 retomadas (`-resume`, 2 folds finais de 363628 no Kaggle) afetam apenas tempos de parede; **(v)** N **por regime (**6–15**)** e **estudos em um único fold externo (fold 0)**; e **(vi) Origem das faixas:** declarada a priori da literatura, mas otimizar AUC causou desalinhamento com a entropia cruzada.

Conclusões

- **Posição do modelo:** o **TabICL v2** superou de forma estatisticamente significativa LightGBM, CatBoost e XGBoost nos $N = 30$ datasets em **AUC OvO** ($F_F = 20{,}695$, $p = 3{,}28 \times 10^{-10}$, posto médio $\mathbf{1{,}300}$, $p_{\text{Holm}} \leq 6{,}33 \times 10^{-5}$) e em **Entropia Cruzada** ($F_F = 24{,}970$, $p_{\text{Holm}} \leq 0{,}0357$).
- **Pontos fortes:** desempenho *zero-shot* — **`group_default` empatou em AUC com `group_tuned`** (0,8607 vs. 0,8606, $p = 0{,}3285$), venceu em 29/30 datasets em Entropia Cruzada (0,3005 vs. 0,3150), liderou em G-Mean (0,6548) e teve menor incerteza de bootstrap, sendo invicto nos pequenos (posto 1,00).
- **Limites:** custo $\mathcal{O}(np^2 + n^2)$ exige GPU de 16 GB e offload para $p > 500$ (latência média de 22,24 s vs. 3,32 s do LightGBM em CPU); perde em alta dimensão esparsa desbalanceada (`hiva_agnostic`); pesos abertos (BSD-3-Clause).
- **Próximos passos:** adotar `group_default` (ou $E = 4$ via 1 EP) em produção; orientar buscas futuras por log-loss/Brier score; avaliar calibração formal (ECE/Platt) e testes bayesianos (Benavoli et al., 2017).

Perguntas?

Repositório: `https://github.com/leticialevleitao/projetoAM20262Q2`
(criado a partir do template `projeto-final-IN1102-2026.2`)

Contato: Douglas Araújo Silva (das7@cin.ufpe.br), Felipe Araújo de Lima (fal6@cin.ufpe.br), Letícia De Albuquerque S. Leitão (lasl@cin.ufpe.br)

Referências principais:

- Qu, J., Holzmüller, D., Varoquaux, G., Le Morvan, M. (2025, 2026). *TabICL (ICML 2025)* & *TabICLv2 (arXiv:2602.11139v2)*.
- Erickson, N. et al. (2025). *TabArena: A Living Benchmark for Machine Learning on Tabular Data (arXiv:2506.16791)*.
- Holzmüller, D., Grinsztajn, L., Steinwart, I. (2024). *Better by Default: Strong Pre-Tuned MLPs and Boosted Trees (pytabkit, NeurIPS)*.
- Demšar, J. (2006). *Statistical Comparisons of Classifiers over Multiple Data Sets*. JMLR, 7, 1–30.
- Hastie, T., Tibshirani, R., Friedman, J. (2009). *The Elements of Statistical Learning*, 2nd ed., Springer.