Rubrica de Avaliação do Projeto Final

Aprendizagem de Máquina (IN1102, pós-graduação)

Prof. Leandro Maciel Almeida

2026.2

A nota final do projeto é calculada pela soma dos critérios abaixo. O peso total é 100%, decomposto a partir do esquema 40% (clareza e profundidade na explicação do modelo) + 50% (qualidade e rigor nos experimentos) + 10% (apresentação) publicado no enunciado da disciplina. Na Etapa 2, a nota considera a implementação (verificada por testes de aceitação visíveis e por testes ocultos), o protocolo experimental de treino, validação e teste com o estudo de overfitting, a interpretação estatística e a reprodutibilidade.

Escala de níveis

Cada critério recebe um fator entre 0 e 1, multiplicado pelo peso. As faixas são contíguas, sem lacunas; dentro de cada faixa, o fator é graduado conforme a qualidade das evidências.

- **Ausente** (0): item não entregue. **Item ausente vale 0.**
- **Insuficiente** (acima de 0 e abaixo de 0,50): item presente, porém incorreto, sem evidências ou em desacordo com o protocolo.
- **Básico** (de 0,50 a menos de 0,75): item correto, porém superficial; faltam justificativas ou evidências.
- **Bom** (de 0,75 a menos de 0,95): item completo, com decisões justificadas e evidências adequadas.
- **Excelente** (de 0,95 a 1,00): item completo, com análise aprofundada, evidências quantitativas e narrativa clara.

Tabela 1: Rubrica do Projeto Final (IN1102, pós-graduação, 2026.2). Pesos somam 100%, decompondo o esquema 40 + 50 + 10 do enunciado.

Critério	Peso	Insuficiente	Básico	Bom	Excelente
Clareza e profundidade na explicação do modelo (Etapa 1): subtotal 40%					
Etapa 1: motivação, contexto histórico e intuição	5%	Motivação confusa ou incorreta; sem contexto histórico.	Motivação genérica; contexto citado sem relação com o modelo.	Motivação clara, contexto histórico correto e intuição bem ilustrada.	Motivação situada na literatura recente; intuição convincente e conectada à arquitetura.
Etapa 1: arquitetura, formulação e forma de aprendizado	12%	Arquitetura ou formulação incorretas.	Diagrama presente; formulação ou forma de aprendizado incompletas.	Arquitetura, formulação e forma de aprendizado completas e coerentes, incluindo o tratamento de categóricos e ausentes.	Tudo o anterior, com relação clara entre blocos, representação dos padrões e justificativas teóricas.

Critério	Peso	Insuficiente	Básico	Bom	Excelente
Etapa 1: complexidade, hiperparâmetros e posicionamento na literatura	8%	Sem análise de complexidade nem de hiperparâmetros.	Complexidade citada de forma rasa; poucas referências; espaço de busca sem justificativa.	Complexidade em função de n e p e pico de memória documentados; espaço de busca justificado; literatura coerente.	Complexidade confrontada com os tempos medidos; espaço de busca com fontes; posicionamento detalhado (2023 a 2026, TabArena).
Etapa 1: aplicações práticas e limitações	5%	Limitações ausentes ou incorretas.	Aplicações e limitações genéricas.	Aplicações e limitações específicas do modelo (tamanho, classes, hardware, licença).	Limitações confirmadas ou refutadas pelos resultados experimentais.
Model card (12 seções; avaliado na Etapa 1, com resultados da Etapa 2)	10%	Apenas campos de exemplo, ou menos da metade das seções preenchidas.	Metade ou mais das seções preenchidas, mas com alguma seção vazia, análise quantitativa ausente ou números que não vêm de `results/test.csv` e `results/validation.csv`.	Todas as seções preenchidas, com números de `results/test.csv` (desempenho final) e de `results/validation.csv` (overfitting), protocolo e lock descritos, incerteza por *bootstrap* resumida corretamente e análise segundo Demšar.	Seções 3 (fatores), 7 (análise quantitativa), 8 (overfitting) e 10 (avisos e recomendações) com narrativa rica e evidências; ameaças à validade explícitas.
Qualidade e rigor nos experimentos (Etapa 2): subtotal 50%					
Etapa 2: seleção e caracterização dos 30 datasets	4%	Seleção inválida no validador ou sem tabela.	Seleção válida, sem justificativa dos critérios.	Seleção válida, tabela completa (task ID, n, atributos, classes, % categóricos, ausentes, regime) e critérios justificados.	Tudo o anterior, com discussão da cobertura (binário e multiclasse, categóricos, ausentes) e de seus efeitos nas conclusões.
Etapa 2: implementação e execução do modelo tema (*wrapper*, quando exigido; estudos de sensibilidade e específico, quando exigidos)	9%	Testes de contrato falham ou o modelo não executa no experimento.	Testes visíveis de contrato passam, mas há falhas nos testes ocultos ou em parte dos datasets sem justificativa, ou faltam os estudos exigidos.	Testes visíveis e ocultos passam; `group_default` e `group_tuned` executados nos 30 datasets e 3 folds externos, nas duas fases, com o orçamento do enunciado; estudos exigidos apresentados, por CV interna.	Tudo o anterior, com histórico da busca analisado (convergência, tempo efetivo; o histórico pode vir de buscas com `tune()` no notebook 03), estudos exigidos interpretados à luz da arquitetura e código claro.
Etapa 2: implementação da estatística, do estudo de overfitting e dos relatórios (`demsar.py`, `bootstrap_ci`, `overfitting.py`, `class_errors.py`, regimes, tabelas e gráficos)	9%	Componentes não implementados ou testes de aceitação falhando em sua maioria.	Parte dos testes de aceitação visíveis passa.	Todos os testes visíveis passam; testes ocultos passam em sua maioria.	Todos os testes visíveis e ocultos passam (modo `AM_STRICT=1`); código legível, sem uso de bibliotecas que entregam o protocolo pronto.

Critério	Peso	Insuficiente	Básico	Bom	Excelente
Etapa 2: protocolo experimental e estudo de overfitting (CV aninhada, decisões a priori, congelamento e *commit* do lock, avaliação final única, `check_protocol`; lacuna, curvas de validação, regra de 1 EP, erros por classe)	8%	Protocolo não descrito ou com decisões tomadas sem validação cruzada; estudo de overfitting ausente ou feito fora do treino.	Protocolo descrito e lock entregue, mas sem as declarações a priori ou com estudo de overfitting incompleto (lacuna sem todos os sistemas, curvas sem CV interna ou sem a regra de 1 EP).	Protocolo completo e coerente com `protocolo.lock`, `test_log.csv`, `test_manifest.json` e o histórico git (`check_protocol` aprovado); declarações a priori registradas; correções após `run_validation` restritas a falhas de execução e relatadas; lacuna de todos os sistemas, curvas do modelo tema e do LightGBM com escolha pela regra de 1 EP e matrizes de confusão nas predições de validação; perguntas do notebook 05 respondidas.	Tudo o anterior, com leitura viés-variância articulada à arquitetura do modelo, cautelas discutidas (métrica de treino em modelos de contexto e de vizinhança, validação otimista de `group_tuned`, um único fold externo, `validation.csv` apenas diagnóstico, origem das faixas do espaço de busca) e comparação descritiva entre validação interna e teste.
Etapa 2: interpretação estatística (Friedman e Iman-Davenport, Holm e Bonferroni-Dunn, Nemenyi e CD, Wilcoxon)	10%	Apenas médias ou testes aplicados sem interpretação; folds tratados como observações independentes.	Testes reportados com números, mas interpretação incompleta; perguntas do roteiro parcialmente respondidas.	Todos os passos reportados e interpretados corretamente (pós-testes tratados como testes apenas se F_F rejeitar a hipótese nula); as seis perguntas do roteiro respondidas; diagramas legíveis.	Tudo o anterior, distinguindo significância e magnitude, discutindo multiplicidade entre métricas, divergências entre procedimentos e limites com o N obtido.
Etapa 2: incerteza, análise por regime, custo vs. desempenho e ameaças à validade	5%	Resultados apenas agregados; sem custo nem ameaças à validade.	Parte dos eixos de regime ou do custo analisada; ameaças citadas de forma genérica.	Bootstrap, quatro eixos de regime (com n por célula), custo decomposto e ameaças à validade (inclusive as do protocolo) discutidos.	Tudo o anterior, articulado com a teoria do modelo, com leitura descritiva cuidadosa e recomendações práticas fundamentadas.
Etapa 2: reprodutibilidade e código	5%	Repositório não executa ou faltam `results/test.csv`, `results/validation.csv` ou as predições.	Executa com intervenções manuais não documentadas; CI falhando.	`uv.lock` versionado, comandos documentados, CI verde, arquivos de `results/` entregues (`validation.csv`, `validation_train.csv`, `protocolo.lock`, `test.csv`, `test_log.csv`, `test_manifest.json`, `preds/`, `figures/`), lock comitado antes dos resultados e `check_protocol` aprovado, hash do commit congelado no relatório.	Tudo o anterior, com execução retomável documentada, hardware e tempos registrados e notebooks executando de ponta a ponta.
Qualidade da apresentação: subtotal 10%					
Apresentação: cumprimento do tempo (20 min, 10 + 10)	4%	Critério contínuo: fator = $\max(0;\ 1 - 0{,}1\,d)$, em que d é o total de minutos fora das janelas de 20 min no total (sem tolerância no total) e de 10 ± 1 min em cada bloco (minutos excedentes ou faltantes somados; frações de minuto contam proporcionalmente). Exemplo: total de 22 min com Etapa 1 em 13 min resulta em $d = 2 + 2 = 4$ e fator 0,60.			

Critério	Peso	Insuficiente	Básico	Bom	Excelente
Apresentação: divisão clara entre integrantes	3%	Apenas um integrante apresenta.	Distribuição desequilibrada.	Todos os integrantes apresentam de forma clara.	Distribuição planejada, com transições nomeadas e domínio do conteúdo por todos nas perguntas.
Apresentação: qualidade visual (gráficos, tabelas, slides)	3%	Slides confusos ou ilegíveis.	Slides limpos, mas sem leitura interpretativa.	Slides claros; gráficos e diagramas autoexplicativos.	Slides cuidadosamente elaborados, legíveis a distância, com leitura precisa de cada figura.

Notas operacionais

- A pontuação de cada critério é o produto do peso pelo fator atribuído na escala acima.
- A correção é feita no repositório do grupo, criado a partir do repositório-template `projeto-final-IN1102-2026.2` (privado, com acesso concedido ao professor).
- Os testes são executados na correção com `AM_STRICT=1`, incluindo testes ocultos que verificam a mesma especificação dos testes visíveis em casos adicionais. Alterar assinaturas de funções e classes do trabalho do grupo ou os testes visíveis leva os critérios de implementação ao nível Insuficiente.
- Uso de bibliotecas que entregam o protocolo de Demšar pronto na implementação avaliada leva o critério de implementação da estatística ao nível Insuficiente; o uso apenas para conferência deve ser declarado.
- Nos critérios de interpretação, ausência de evidências quantitativas (estatísticas, p-valores, diagramas, tabelas) limita o fator ao nível Básico.
- **Penalidade por uso indevido do teste.** Qualquer uso do teste anterior ao *commit* do lock (por exemplo, escolher hiperparâmetros, faixas do espaço de busca, grades, regras de contexto ou datasets olhando o teste), qualquer reexecução da avaliação final (por exemplo, apagar `results/test.csv`, `test_log.csv` ou o manifesto e executar `final_test` de novo, ou recongelar depois de ver o teste), resultados comitados no mesmo *commit* do lock ou sem lock comitado, e alterações de arquivos travados depois do teste sem justificativa **anulam** (fator 0) os critérios de implementação (modelo tema; estatística, overfitting e relatórios) e de interpretação (protocolo e overfitting; interpretação estatística) da Etapa 2. Retomadas com `--resume` para completar pendências ou erros, com o mesmo lock e explicadas no relatório, não são penalizadas.
- **Verificação do protocolo.** A correção executa `python -m src.pipeline.check_protocol` sobre o histórico git do repositório entregue: o *commit* do lock deve anteceder o primeiro *commit* com `test.csv` ou `test_log.csv`; `test_log.csv` deve registrar uma única avaliação inicial (retomadas só de pendências ou erros); os hashes do lock devem conferir com os arquivos no *commit* do lock, no *commit* da avaliação e em `HEAD`; nenhum *commit* posterior pode alterar arquivos travados sem justificativa. A justificativa é registrada em uma linha iniciada por `Justificativa:` na mensagem do *commit* que altera o arquivo travado (por exemplo, com um segundo `-m`); mesmo justificada, a alteração aparece como aviso no `check_protocol`, é examinada na correção e deve ser explicada no relatório. Reprovação em `check_protocol` é tratada como uso indevido do teste, salvo explicação técnica aceita. Também são conferidos `results/test_manifest.json`, `results/protocolo.lock` e as datas dos commits. Histórico reescrito (*rebase*, *amend* ou *push* forçado) depois do *commit* do lock é tratado como ausência de evidência.
- **Uso de `validation.csv`.** Os resultados da fase de desenvolvimento são apenas diagnóstico: depois de `run_validation`, só são aceitas correções de falha de execução registradas no relatório. Mudanças de sistema, controle, espaço de busca ou orçamento motivadas por desempenho são tratadas como violação do protocolo.
- **Resultados do *leaderboard* do TabArena.** O uso dos resultados por dataset do *leaderboard* (ou dos *runs* e avaliações publicados no OpenML para essas *tasks*) na seleção dos datasets ou na definição do espaço de busca é tratado como uso indevido do teste.
- Outras violações do protocolo (orçamento de busca diferente do enunciado sem justificativa, folds tratados como datasets independentes nos testes, estudos sem validação cruzada) zeram os critérios da Etapa 2 que dependem dos resultados afetados.

- O espaço de busca (faixas, escalas e fontes) é avaliado apenas no critério de complexidade, hiperparâmetros e posicionamento da Etapa 1; o critério de implementação da Etapa 2 avalia o código, a execução e os estudos exigidos.
- Carga equivalente entre modelos: os grupos de TabDPT-1.3, ModernNCA e TabR implementam o *wrapper* completo do modelo tema; os grupos cujo modelo tem API *scikit-learn* nativa (TabPFN-3.5, TabICL v2, TabM, RealMLP, FT-Transformer, xRFM, EBM e APLR) apresentam, em compensação, o estudo de sensibilidade a 2 hiperparâmetros e o estudo específico do modelo descritos no enunciado. A ausência desses itens limita o critério de implementação do modelo tema ao nível Básico.
- A análise bayesiana (Benavoli et al., 2017) é extensão opcional: não é exigida para o nível Excelente, mas, se apresentada corretamente, pode compensar deficiências pontuais no critério de interpretação estatística.