Projeto Final: Aprendizagem de Máquina (IN1102, pós)

Modelo tema: **[NOME DO MODELO]**

Grupo: **[INTEGRANTES]**

Pós-graduação, CIn/UFPE, 2026.2

Apresentação

Agenda

Etapa 1: fundamentação teórica do modelo (10 minutos)

- Motivação, contexto e intuição
- Arquitetura, formulação e forma de aprendizado
- Complexidade, hiperparâmetros e posicionamento na literatura
- Aplicações e limitações

Etapa 2: estudo experimental (10 minutos)

- Seleção dos 30 datasets e protocolo de treino, validação e teste
- Estudo de overfitting e viés-variância
- Resultados no teste e teste de Friedman (Iman-Davenport)
- Controle com Holm e Bonferroni-Dunn; Nemenyi e diagrama CD
- Padrão vs. com busca, regimes, custo e conclusões

Etapa 1: motivação e contexto

- Classificação tabular: *gradient boosting* ainda é referência.
- Novos paradigmas: modelos de fundação com aprendizado em contexto, MLPs modernas, modelos aditivos, métodos de vizinhança e de *kernels*.
- **Pergunta:** em quais regimes o modelo [X] é competitivo com LightGBM, XGBoost e CatBoost?

Contexto histórico: [trabalhos que originaram o modelo].

Etapa 1: intuição do modelo

- Ideia central em uma frase: [...].
- Diferença em relação aos baselines: [...].
- Fundamento teórico ou heurístico: [...].

[diagrama conceitual]

Etapa 1: arquitetura

[diagrama de blocos da arquitetura]

Componentes principais: [bloco A], [bloco B], [bloco C].

Etapa 1: formulação e forma de aprendizado

- Função de perda: [...]
- Regularização: [...]
- Como aprende: [treino por gradiente, pré-treino, boosting, ...]
- Representação dos padrões: [embeddings, funções de forma, vizinhanças, ...]
- Categóricos e valores ausentes: [tratamento]

Etapa 1: complexidade computacional

Operação	Tempo	Memória	Observação
Treino	O(...)	O(...)	[crescimento com n e p]
Inferência	O(...)	O(...)	[latência típica]

Pico de memória observado: [valor em GB] em [dataset]; hardware: [CPU/GPU].

Etapa 1: hiperparâmetros e espaço de busca

Hiperparâmetro	Padrão	Faixa de busca (Optuna)	Efeito esperado
[hp1]	[...]	[...]	[compromisso entre viés e variância]
[hp2]	[...]	[...]	[efeito sobre o tempo de treino]
[hp3]	[...]	[...]	[...]

Fonte das faixas: [artigo, documentação, TabArena].

Etapa 1: posicionamento na literatura

- 2023: [trabalho A].
- 2024: [trabalho B] e [trabalho C].
- 2025: [trabalho D], [trabalho E] e o modelo [X].
- 2026: [trabalhos correlatos recentes; posição no TabArena].

O modelo [X] se diferencia por: [diferenciador 1], [diferenciador 2].

Etapa 1: aplicações e limitações

- Aplicações práticas: [domínios e casos de uso].
- Restrições de tamanho (n e p máximos, número de classes).
- Suposições sobre os dados (IID, tipos de atributos).
- Requisitos: [GPU, memória, licença de pesos].

Etapa 2: datasets, sistemas e métricas

- **Datasets:** 30 do TabArena-v0.1 (10 pequenos, 10 médios, 10 grandes), escolhidos pelo catálogo antes de qualquer resultado; critério: [...].
- **Sistemas:** [X] padrão e [X] com busca; LightGBM, XGBoost e CatBoost (TD).
- **Busca:** Optuna (otimização bayesiana, TPE) no treino de cada fold externo, 20 tentativas, CV interna 3, 600 s por fold (tempo efetivo: [...]), subamostra de até 10.000.
- **Espaço de busca:** justificado a priori por [artigo, documentação].
- **Métricas:** AUC OvO (primária), ACC, G-Mean, CE e custo.

Etapa 2: protocolo de treino, validação e teste (CV aninhada)



Treino de cada fold externo: CV interna de 3 folds com a busca e todos os estudos (sensibilidade, específico, curvas, overfitting).

Teste de cada fold externo: selado; usado uma única vez.

1. Desenvolvimento
`run_validation`, notebooks 02, 03 e 05
`validation.csv` (diagnóstico)

→

2. Congelamento
`freeze` e `git commit`
`protocolo.lock`: hashes e orçamento

→

3. Avaliação final única
`final_test` e `git commit`
`test.csv`, `test_log.csv`; `check_protocol`

→

4. Análise
média dos 3 testes por dataset
Demšar com $N = 30$

Lock: commit [hash] (anterior aos resultados, commit [hash]), sha256 [...]; execuções em `test_log.csv`: [n] ([modos]); `check_protocol`: [aprovado]. Declarados a priori: [espaço de busca e origem das faixas, datasets dos estudos, grades].

Etapa 2: overfitting, lacuna treino-validação

Sistema	Treino	Validação	Lacuna
[X] padrão	0,xxx	0,xxx	0,0xx
[X] com busca	0,xxx	0,xxx	0,0xx
LightGBM (TD)	0,xxx	0,xxx	0,0xx
XGBoost (TD)	0,xxx	0,xxx	0,0xx
CatBoost (TD)	0,xxx	0,xxx	0,0xx

AUC OvO, CV interna no treino dos folds externos; lacuna > 0 indica overfitting.

[barras da lacuna por sistema]

Leitura: [onde a lacuna é maior; efeito do regime de tamanho; cautela com métrica de treino em modelos de contexto ou de vizinhança e com a validação otimista do sistema com busca].

Etapa 2: curvas de validação e regra de 1 erro padrão

[curva do modelo tema: hiperparâmetro [hp]] [curva do LightGBM: `num_leaves`]

- Datasets (declarados a priori, um por regime): [...]; CV interna no treino de um fold externo.
- Melhor média: [valores]; regra de 1 EP: [valores]; dentro da faixa da busca? [sim/não].
- Viés e variância: [região da configuração padrão; subajuste ou sobreajuste].
- Erros por classe na validação (`plot_confusion`): [classes com menor recall; relação com o G-Mean].

Etapa 2: resultados no teste (avaliação final única)

Sistema	AUC OvO	Posto médio	Tempo (s)
[X] padrão	0,xx ± 0,0xx	N/A	xxx
[X] com busca	0,xx ± 0,0xx	x,xx	xxx
LightGBM (TD)	0,xx ± 0,0xx	x,xx	xxx
XGBoost (TD)	0,xx ± 0,0xx	x,xx	xxx
CatBoost (TD)	0,xx ± 0,0xx	x,xx	xxx

Média ± desvio entre os N = [N] datasets completos (média dos testes dos 3 folds externos por dataset).
Validação interna vs. teste: [diferença; otimismo do sistema com busca].

Etapa 2: teste de Friedman com correção de Iman-Davenport

- $k = 4$ sistemas, $N =$ [N] datasets, $\alpha = 0{,}05$.
- $\chi^2_F =$ [valor]; $F_F =$ [valor] com ([gl1], [gl2]) graus de liberdade; p = [valor].
- Decisão (por F_F): [rejeita ou não rejeita a hipótese nula]. Se não rejeitar, os pós-testes seguintes são apenas descritivos.
- Datasets excluídos pela regra de completude: [quais e por quê].

Etapa 2: modelo do grupo como controle (Holm e Bonferroni-Dunn)

vs. controle	z	**p (Holm)**
LightGBM (TD)	x,xx	0,xxx
XGBoost (TD)	x,xx	0,xxx
CatBoost (TD)	x,xx	0,xxx

[diagrama de Bonferroni-Dunn]

Etapa 2: análise complementar (Nemenyi e diagrama CD)

[diagrama de diferença crítica, Nemenyi]

CD = [valor]; grupos sem diferença significativa: [...].

Etapa 2: padrão vs. com busca (Wilcoxon)

- Diferenças usadas = [n] de N = [N]; R^+ = [valor], R^- = [valor], T = [valor], p = [valor].
- Vitórias, empates e derrotas da variante com busca: [v / e / d].
- Custo da busca: [tempo efetivo mediano por fold].
- A busca compensa? [resposta baseada nos números].
- Sensibilidade a 2 hiperparâmetros e estudo específico do modelo (grupos com API scikit-learn nativa): [leitura principal].

Etapa 2: análise por regime (descritiva)

[tamanho: pequeno, médio, grande] [classes, proporção categórica, valores ausentes]

Número de datasets por célula: [...]; leitura apenas descritiva.

Etapa 2: custo vs. desempenho

[tempo total mediano por fold (escala log) vs. AUC OvO média, cinco sistemas]

Posição do modelo do grupo na fronteira de Pareto: [...].

Etapa 2: pontos fortes, pontos fracos e ameaças à validade

- Melhor desempenho em: [regime] (exemplo: [dataset], diferença $= +0{,}0xx$).
- Pior desempenho em: [regime] (exemplo: [dataset], diferença $= -0{,}0xx$).
- Causa provável: [propriedade dos dados ou limite do modelo].
- Ameaças à validade: [assimetria de busca, imputação, subamostragem, falhas, N por regime, estudos em um único fold externo, origem das faixas do espaço de busca].

Conclusões

- Posição do modelo: [resumo em uma frase, com o resultado estatístico].
- Pontos fortes: [...]
- Limites: [restrições de n, p, regime, custo, licença de pesos].
- Próximos passos: [métricas adicionais, calibração, análise bayesiana opcional].

Obrigado

Perguntas?

Repositório: `[link]` (criado a partir do template `projeto-final-IN1102-2026.2`)
Contato: [e-mails dos integrantes]
Referências principais: [3 a 5 itens]